BIÊN BẢN CHU KỲ 01 — 26/10 đến 06/11/2026

1. Tóm tắt
2. Việc Brain — trạng thái
3. Cổng ra chu kỳ (SRS §7)
4. Việc treo của TIEN_TRINH
5. Phát hiện ngoài kế hoạch, đã xử lý
    5.1. Model chép sai đầu vào tool — chốt đầu vào (`src/core/doc_dau_vao.py`)
    5.2. Model suy biến — chốt suy biến (`grounding.kiem_suy_bien`)
    5.3. Các quyết định chủ dự án đã chốt trong chu kỳ
6. CI từng bị khoá — đã gỡ 03/11, BR-07 nghiệm thu 09/11
7. Đẩy sang chu kỳ 02
    7.1. Theo kế hoạch
    7.2. Đầu vào cho vòng huấn luyện lại (lỗi do **dữ liệu**, BAO_CAO_BR05)
    7.3. Hở đã biết của các chốt mới
    7.4. Khung đo
8. Chi phí thật (NFR-02)
9. Việc còn mở, cần quyết trước khi khép chu kỳ
10. Phần Body (đội Body điền)

BIÊN BẢN CHU KỲ 01 — 26/10 đến 06/11/2026

Viết: 29/10/2026, **cập nhật 09/11/2026** (CI đã gỡ khoá, nghiệm thu BR-07) · **Phần Brain:** Thành · **Phần Body:** Sĩ, Sơn, Nam (mục 10, chờ điền) **Đặc tả:** SRS_CHU_KY_01.md · **Phân việc:** PHAN_VIEC_CHU_KY_01.md **Nhánh:** `feat/workflow-format-and-deterministic-core` @ `fffbabd` — chưa mở PR, chưa merge `main`

Khuôn theo PHAN_VIEC mốc M2: **cái gì xong, cái gì trượt kèm lý do, cái gì đẩy sang chu kỳ 02.** Số liệu chi tiết nằm ở BAO_CAO_BR04.md và BAO_CAO_BR05.md; biên bản này chỉ dẫn tới.

---

1. Tóm tắt

1. **Mục tiêu S2 đạt:** `/chat` chạy qua vLLM server thật trên Colab L4, có log server ghi nhận request của Brain, cùng vision đang nạp.
2. **Cả 6 việc Brain của chu kỳ xong phần mã** (BR-01 đến BR-05, BR-07); BR-06 đã chuyển chu kỳ 02 theo SRS. BR-07 đã nghiệm thu trên CI thật ngày 09/11, sau khi khoá thanh toán GitHub được gỡ ngày 03/11 (mục 6).
3. **Đo bản fine-tune xong, kể cả so cặp với bản gốc:** giữ fine-tune — làm hỏng 8 câu, sửa 88 câu. Lỗi còn lại phần lớn là **dữ liệu huấn luyện**, đầu vào cho quyết định huấn luyện lại ở chu kỳ 02.
4. **Lộ ra và đã chặn hai lớp lỗi R1 mà chốt cũ không bắt:** model **chép sai đầu vào tool** rồi tool tính đúng trên số sai (Brain báo 5.500.000 thay vì 6.050.000), và model **suy biến** ra rác chữ Hán/lặp tới trần token. Cả hai nay có chốt tất định ở production.
5. **Không phát sinh chi phí mới** — Colab Pro sẵn có (NFR-02).

---

2. Việc Brain — trạng thái

Việc	Ưu tiên · hạn	Trạng thái	Bằng chứng
BR-01 `/tools/vat` từ chối trường lạ	P0 · 27/10	**Xong**	`7214df1` , `553e396` ; trả 422, không tính bằng 0
BR-02 Đường chat cho `VLLMServerClient`	P0 · 29/10	**Xong**	`5f3e37b` ; ba bất biến payload có test: chat template, `enable_thinking=False` , `repetition_penalty=1.0` khi bật grammar
BR-03 `engine.py` rẽ theo backend	P0 · 02/11	**Xong**	`8b69afb` ; nghiệm thu trên Colab: log vLLM ghi `POST /v1/chat/completions 200` từ Brain

Việc	Ưu tiên · hạn	Trạng thái	Bằng chứng
BR-04 vLLM trên L4, ngân sách ctx	P0 · 04/11	**Xong** (9/10 yêu cầu)	BAO_CAO_BR04; ctx **chốt 32768**, p95 **chốt hai ngưỡng**. Yêu cầu 8 chưa đo → chu kỳ 02
BR-05 Đo fine-tune, bảng phân loại lỗi	P1 · 05/11	**Xong** (9/9 yêu cầu)	BAO_CAO_BR05 §3 (bảng phân loại), §6d (so cặp với bản gốc)
BR-06 Bộ đo RAG	—	**Chuyển chu kỳ 02**	Quyết định trong SRS, không phải trượt
BR-07 Mở rộng cổng lint CI	P2 · 06/11	**Xong, đã nghiệm thu 09/11**	`31aafa1` : `ruff check src tests offline_training` . Nghiệm thu trên CI thật: thêm `l = 1` → bước Ruff **đỏ** (lượt 42626504006 (https://github.com/ANSER-Logistics/ANSER_AI_Logistics/actions/runs/42626504006)); gỡ ra → **xanh** cả bốn bước (lượt 42626530275 (https://github.com/ANSER-Logistics/ANSER_AI_Logistics/actions/runs/42626530275)) — mục 6

3. Cổng ra chu kỳ (SRS §7)

Mục	Trạng thái
`/chat` qua vLLM server, có phép thử chứng minh server **nhận** request (BR-03)	**Đạt** — log vLLM ghi 2 request của Brain cho câu hoá đơn (BR-04 §5.2)
Ba bẫy §3.3 có phép thử riêng và xanh (BR-02)	**Đạt** — cộng **bẫy thứ tư** tìm ra trong BR-04: xgrammar bỏ qua khoá đứng cạnh `oneOf` , grammar agentic không thi hành trên server; sửa `82e9e9c` , test bằng xgrammar thật
Ngân sách ctx đo trên L4, ≥ 3 mức, **với vision đang nạp**; quyết định vào ARCHITECTURE (BR-04)	**Đạt** — 8192/16384/32768 đều dựng được, KV 36.176 token ở gmu 0,55, VRAM đỉnh 21,1 GB; chốt 32768 và `ANSER_TEXT_MAX_CONCURRENT=4`
Bảng ARCHITECTURE §5.1 sửa (vision bf16 7,5 GB) (BR-04)	**Đạt** — đo 7.874 MiB
Bảng phân loại lỗi fine-tune theo nhánh, số ca, ví dụ nguyên văn, quy về ba nguyên nhân (BR-05)	**Đạt** — BAO_CAO_BR05 §3
`/tools/vat` trả 422 cho trường lạ (BR-01)	**Đạt**

Mục	Trạng thái
`pytest -q` xanh và `ruff` sạch trên đúng mã đã đo	**Đạt, kèm ghi chú** — `fffbabd` trên Colab: **1163 passed, 4 skipped**; ruff **All checks passed** trên cả `src tests offline_training`. Phiên so cặp chạy ở `31aafa1`; các commit sau đó thêm chốt suy biến, biến env và test, không đổi đường đo trừ `per_row` của bảng hệ thống. Lúc viết (29/10) CI chưa chạy được nên xanh là do chạy tay; từ 03/11 CI chạy thật và nhánh làm việc **xanh** liên tục (lượt `c3e03ea` ngày 09/11)
Biên bản ghi treo 1 và 2, chi phí thật, danh sách sang chu kỳ 02	**Đạt** — mục 4, 5, 7 của biên bản này

---

4. Việc treo của TIEN_TRINH

Treo	Trạng thái
#1 `render_tools()` từng quảng cáo trường hệ thống tự bơm	**Đề xuất đóng, chờ chủ dự án** — sau khi sửa bảng luật (BR-05 §6b), agentic: chịu gọi tool 100%, điền tham số đúng kiểu 100% (n=9), không ca agentic nào cắt cụt ở cả ba lần đo 28–29/10. Lý do chưa tự đóng: n=9 nhỏ, và lỗi gốc (mảng `lines` dài tràn trần) không còn câu nào trong bộ đề tái hiện
#2 Đo lại sau khi có `providers.py`	**Đóng 27/10** — `[chốt chặn] ràng buộc JSON: ✓ CHẠY`
#3 Ba phần hạ tầng khai báo mà chưa nối	Không thuộc chu kỳ này
#4 RAG chưa có thước đo	Đi cùng BR-06 → chu kỳ 02
#5 Model chép thiếu đầu vào cho tool (mở 26/10)	**Đóng 28/10** — xem mục 5.1

---

5. Phát hiện ngoài kế hoạch, đã xử lý

5.1. Model chép sai đầu vào tool — chốt đầu vào (`src/core/doc_dau_vao.py`)

Câu hoá đơn 5.000.000 + 500.000, model gửi cho `vat` **một** dòng; Brain trả lời "tổng thực tế 5.500.000đ" kèm "kết quả từ công cụ VAT" — sai mà trông có nguồn. Chủ dự án chốt làm cả hai cách, theo trường hợp:

Đã làm	Ghi chú
B — hoá đơn dán có cấu trúc thì mã bóc dòng hàng, ghi đè model; câu liệt kê ≥ 2 lời chào giá thì mã dựng `carriers` / `offers`	`carrier_selection` trước đó luôn hỏi lại vì "chưa có nguồn"

Đã làm	Ghi chú
A hai chiều — số tiền trong câu phải có trong tham số (thiếu), số tiền trong tham số phải có trong câu (bịa)	đọc cả số bằng chữ ("năm triệu rưỡi") và nói tắt ("12tr5")
Giá đã gồm VAT hay chưa: câu không nói thì **hỏi lại**; lượt trả lời được ghép với hoá đơn lượt trước	chủ dự án chốt; tool `vat` có thêm chế độ giá đã gồm thuế
Tham số chính sách giá câu không nói tới (`fuel_sensitivity` , `min_margin_amount` , `fuel_baseline_price`) thì **mã xoá**, tool dùng mặc định	model điền `fuel_sensitivity` 0,05 thay 0,35 ở 2/2 câu — chốt số tiền không bắt được
Một hàm `chot_dau_vao` dùng chung cho production và benchmark	đo đúng thứ chạy thật (R4)

Kết quả trên vLLM thật: câu hoá đơn ra **6.050.000, chênh 450.000** (đúng). Benchmark qua chốt: **an toàn 100%, lọt 0** với cả bản gốc lẫn fine-tune; trả lời ngay 44,4% (gốc) và 100% (fine-tune).

5.2. Model suy biến — chốt suy biến (`grounding.kiem_suy_bien`)

6–13/27 câu diễn giải của bản fine-tune hết ý thì trôi sang chữ Hán hoặc kê từ tiếng Anh, rồi lặp tới trần 2048 token. Đo `repetition_penalty` 1,25 / 1,1 / 1,0: hạ phạt giảm suy biến nhưng không hết và bịa số tăng — **gốc ở dữ liệu huấn luyện**. Chủ dự án chốt giữ 1,25, thêm chốt: câu có chữ Hán hoặc 100 ký tự cuối lặp nguyên văn thì thay câu an toàn. Chốt số liệu không bắt được loại này vì rác không có số.

5.3. Các quyết định chủ dự án đã chốt trong chu kỳ

Ngày	Quyết định
28/10	`TEXT_MAX_MODEL_LEN` 32768
28/10	"Báo giá" tách ba ý định: xin báo giá → n8n; tính giá bán → `quote` ; so lời chào → `carrier_selection`
28/10	Chép sai đầu vào: làm cả A và B theo trường hợp; `carrier_selection` đọc lời chào từ câu
28/10	Giá không nói gồm VAT chưa → hỏi lại
28/10	p95 hai ngưỡng: ≤ 60 ms/token (`P95_MS_MOI_TOKEN`) và ≤ 5.000 ms tổng (`P95_NGUONG_MS`)
28/10	Tham số chính sách giá model bịa → mã xoá, dùng mặc định
29/10	Suy biến: giữ `repetition_penalty` 1,25, thêm chốt

---

6. CI từng bị khoá — đã gỡ 03/11, BR-07 nghiệm thu 09/11

Lúc viết biên bản (29/10): GitHub Actions của repo có **136 lượt, 0 lượt xanh**. Mọi job kết thúc với "*The job was not started because your account is locked due to a billing issue*", từ lượt cũ nhất đã soi (14/05/2026). Khoá ở tài khoản chủ repo, không phải tài khoản người đẩy mã. Nghĩa là trong khoảng đó **không có cổng tự động nào hoạt động**, và mọi chỗ trong tài liệu cũ nói "CI xanh" không có lượt chạy nào chứng minh.

Đã gỡ 03/11/2026 (xem commit `ff38ff4`). Từ đó CI chạy thật, và được mở rộng thêm ngoài BR-07: `mypy src offline_training`, ruff thêm hai script ở gốc repo, `.pre-commit-config.yaml` chạy ruff, mypy và quét secret ở máy dev. Repo cũng đã dời sang tổ chức `ANSER-Logistics/ANSER_AI_Logistics`.

Nghiệm thu BR-07 (09/11): nhánh phụ `ci/br07-nghiem-thu-2` dựng từ `c3e03ea`, hai commit:

Commit	Thay đổi	CI	Các bước
`e057f2c`	thêm `l = 1` vào `src/core/nguong_p95.py` (ruff E741)	**đỏ**	Ruff ✗ · Mypy, Pytest, Dataset preflight bỏ qua
`49d7711`	gỡ ra	**xanh**	Ruff ✓ · Mypy ✓ · Pytest ✓ · Dataset preflight ✓

Hai commit chỉ khác nhau đúng một dòng, nên bước Ruff đỏ là do lỗi được cài vào chứ không vì gì khác. Đạt đúng yêu cầu SRS: "*lỗi mới PHẢI làm CI đỏ*". Hai nhánh phụ (`ci/br07-nghiem-thu` của 29/10 và `ci/br07-nghiem-thu-2`) **giữ lại** làm bằng chứng nghiệm thu.

---

7. Đẩy sang chu kỳ 02

7.1. Theo kế hoạch

Việc	Ghi chú
BR-06 bộ đo RAG	SRS chuyển từ đầu chu kỳ
BR-04 yêu cầu 8 — ctx đủ cho kế hoạch 3 tool + RAG, đo bằng ca thật	cần RAG có thước đo trước; đi cùng BR-06
Huấn luyện lại model	SRS: không làm chu kỳ này; bảng phân loại lỗi là đầu vào

7.2. Đầu vào cho vòng huấn luyện lại (lỗi do **dữ liệu**, BAO_CAO_BR05)

Lỗi	Quy mô	Nguồn
Narration không biết dừng → suy biến tới trần token	6–13/27 câu	§6d
Chép sai dấu ngăn nghìn → số lệch ×10 (12.709.000 → 127.090.000)	lặp lại ở mọi mức phạt	§3, §6d
Extraction điền bừa trường đáng để trống (xưng hô thành tên, mặc định `dau_keo` / `Hà Nội`)	~53 ca	§3
Extraction tự tính ngày tương đối — LLM làm phép tính, trái R1	~21 ca	§3
Workflow n8n trỏ tới node `noOp` không khai	2/4 ca n8n trượt	§6d
Bộ đề: ~10 nhãn extraction sai; nhãn "phải hỏi lại" của AG0009 có thể tranh cãi	—	§3, §6b

7.3. Hở đã biết của các chốt mới

Hở	Hệ quả
Kê từ tiếng Anh mà chưa kịp lặp thì chốt suy biến chưa bắt	rác có thể lọt
Model bỏ giá dầu lúc chốt bảng giá → vẫn phải hỏi lại khách (AG0015)	khách mất một lượt; sửa bằng bộ bóc riêng cho câu tính giá
Cách A có thể hỏi lại thừa khi câu nhắc số tiền không phải đầu vào	khách mất một lượt
`carrier_selection` chỉ xếp theo giá / chiết khấu / công nợ có trong câu	tiêu chí khác tool tự bỏ
Hoá đơn không nói gồm VAT chưa luôn tốn thêm một lượt	theo quyết định 28/10

7.4. Khung đo

Việc	Ghi chú
Câu không có kế hoạch tool vẫn bị chấm qua vòng agentic, trong khi production đưa sang nhánh router	là lý do "biết hỏi lại" kẹt 25% — BAO_CAO_BR05 §6b
Kết quả dao động ±1 ca giữa các lần chạy dù `temperature=0`	batching vLLM; cần đo nhiều lần hoặc tăng bộ đề

---

8. Chi phí thật (NFR-02)

Khoản	Số
Hạ tầng mới	**0đ** — Colab Pro sẵn có, không thuê GPU
GPU dùng	Colab L4, nhiều phiên 26–29/10 (BR-04, BR-05 ba lần đo, so cặp, đo phạt lặp). Không ghi số giờ chính xác
Model tải thêm	`Qwen/Qwen3-8B-AWQ` (HF, miễn phí) cho so cặp

---

9. Việc còn mở, cần quyết trước khi khép chu kỳ

#	Việc	Ai	Trạng thái 09/11
1	Gỡ khoá thanh toán GitHub	chủ repo	**Xong 03/11** — mục 6
2	Đóng treo #1 hay đo thêm (mục 4)	chủ dự án	**Còn mở**
3	Thư mục `docs/ban-in/BR05` (dữ liệu đo, chưa vào git): chuyển lên Drive hay `.gitignore`	chủ dự án	**Còn mở**

#	Việc	Ai	Trạng thái 09/11
4	Dựng lại bản PDF `docs/ban-in`	Thành	**Xong 29/10** (`e1d5e49`), dựng lại sau bản cập nhật này
5	Mở PR cho nhánh làm việc để review (không merge `main`)	chủ dự án	**Còn mở**
6	~~Sửa câu "không tự tạo notebook" trong SỔ_TAY và AGENTS~~	—	**Ghi nhầm:** câu đó đã sửa từ 26/10, lẽ ra không có mục này
7	Xoá nhánh nghiệm thu BR-07	Thành	**Không xoá** — giữ làm bằng chứng nghiệm thu

---

10. Phần Body (đội Body điền)

Việc	Người	Trạng thái	Ghi chú
BD-01 Gộp `feat/brain-integration` về `Dgsonn/ANSER-v2`	Sĩ, Sơn		
BD-02 Chốt một bản `schema.ts` duy nhất và báo Brain	Sơn		
BD-03 Giữ phép thử hợp đồng đường dẫn chạy được	Nam		
BD-04 Đưa Body lên chỗ khách truy cập được	Nam		